PsyBer-Agent：心理驱动的推荐系统用户Agent

设离线交互数据为 $\mathcal{D}=\{(u,v,t)\}$，其中 u **表示用户，**v **表示 item，**t **表示时间戳**。对推荐数据集中的任意用户，按时间升序整理其交互记录（主要是点击 item 的次序），得到一条专家轨迹 $E=(v_1,\ldots,v_n)$，其中 n 表示该用户轨迹长度，v_i 表示第 i 个交互 item。

与此对应，设 Agent 在一次交互过程中产生的心理状态轨迹为 $A=(s_1,\ldots,s_m)$，其中 m 表示 Agent 轨迹长度，在推荐场景下可以理解为 User 连续浏览的次序，且：

$$s_j=[P_j,C_j,E_j,S_j]\in\mathbb{R}^4 \tag{1}$$

详情请见 **Psy-Engine Modelling** 文档（附件一），这是一个详细的心理学状态转移模型。s_j 表示 Agent 在第 j 步的心理状态，四个分量分别对应 **感知层** P、**认知层** C、**情感/社会层** E，**和自我层** S。

进一步地，记 Agent 在第 j 步的心理因素状态增量为

$$\Delta s_j=\begin{cases}s_{j+1}-s_j, & 1\le j<m,\\ 0, & j=m,\end{cases} \tag{2}$$

用于描述相邻步之间的心理变化趋势。

由于专家路径是 item 序列点击序列、Agent 侧数据则表现为随时间变化的四维心理状态轨迹 (P_j,C_j,E_j,S_j)，我们分别在两个域内定义内部距离。其中，$i,i'\in\{1,\ldots,n\}$ 表示**专家轨迹** $E=(v_1,\ldots,v_n)$ 中的两个位置索引，分别对应第 i 个和第 i' 个交互 item，即 v_i 与 $v_{i'}$。这里的撇号 $(')$ 仅用于表示“同一序列中的另一个位置”，**并不表示导数，也不一定表示相邻位置**。因此，$d_E(i,i')$ 衡量的是专家轨迹中两个 item 位置之间的内部结构关系，$d_A(j,j')$ 衡量的是 Agent 轨迹中两个心理状态位置之间的内部结构关系。

对于专家轨迹，设 $g(v)$ 表示 item v 的表征向量，则专家侧的内部距离定义为：

$$d_E(i,i')=\lambda_v\big(1-\cos(g(v_i),g(v_{i'}))\big)+\lambda_t\left|\frac{i}{n}-\frac{i'}{n}\right|, \tag{3}$$

其中 **第一项描述两个 item 在空间中的差异**，第二项描述它们在 **序列位置上的差异**。对 Agent 轨迹，定义内部距离为

$$d_A(j,j')=\lambda_s\|s_j-s_{j'}\|_2+\lambda_\Delta\|\Delta s_j-\Delta s_{j'}\|_2+\lambda_t'\left|\frac{j}{m}-\frac{j'}{m}\right|. \tag{4}$$

其中 **第一项刻画心理状态差异，第二项刻画心理变化趋势差异，第三项约束轨迹中的相对时间位置。**

这样，专家侧和 Agent 侧都被表示为“带内部结构的序列对象”。在此基础上，引入 OT 方法，记 $C\in\mathbb{R}_+^{m\times n}$，其中 $C_{j,i}$ 表示 Agent 第 j 步与专家第 i 个 item 之间的软匹配强度。设 $a\in\mathbb{R}_+^m$，$b\in\mathbb{R}_+^n$，分别为 Agent 侧和专家侧的边缘分布，通常可取归一化均匀分布。进一步地，在 UGW 目标中，(j,j') 与 (i,i') 组成了一个“关系对关系”的比较单元：我们不是直接比较某个 Agent 状态和某个 item 是否相似，而是比较 Agent 侧第 j,j' 两步之间的关系，是否与专家侧第 i,i' 两个 item 之间的关系一致。

为避免直接对传输矩阵 C 采用均匀初始化，我们先基于离线专家轨迹 $E=(v_1,\dots,v_n)$ 构造一个回归式初始对齐。具体地，对每条专家轨迹，在对应用户 u 的画像条件下，利用 Psy-Engine 按 item 顺序进行 teacher forcing，得到专家侧伪心理状态轨迹 $(\tilde{s}_1,\dots,\tilde{s}_n)$，其中 $\tilde{s}_i\in\mathbb{R}^4$ 表示专家轨迹在第 i 个位置对应的伪心理状态。进一步地，在离线数据上训练回归函数 f_ϕ，其中 ϕ 表示回归模型参数，$E_{1:i}=(v_1,\dots,v_i)$ 表示专家轨迹前缀。对专家侧第 i 个 item，利用用户标识 u、轨迹前缀 $E_{1:i}$、item 表征向量 $g(v_i)$ 及相对位置 $\frac{i}{n}$，回归得到与 Agent 心理状态同构的四维伪状态

$$\hat{s}_i=f_\phi\left(u,E_{1:i},g(v_i),\frac{i}{n}\right)\approx\tilde{s}_i,\qquad \hat{s}_i\in\mathbb{R}^4. \tag{5}$$

其中，f_ϕ 通过最小化离线回归损失进行训练：

$$\phi^\star=\arg\min_\phi\sum_u\sum_{i=1}^{n}\left\|f_\phi\left(u,E_{1:i},g(v_i),\frac{i}{n}\right)-\tilde{s}_i\right\|_2^2. \tag{6}$$

进一步地，定义其状态增量为

$$\Delta\hat{s}_i=\begin{cases}\hat{s}_{i+1}-\hat{s}_i, & 1\le i<n,\\ 0, & i=n.\end{cases} \tag{7}$$

于是，对于 Agent 第 j 步与专家第 i 个 item，定义回归初始化代价：

$$r_{j,i}=\|s_j-\hat{s}_i\|_2^2+\lambda_\Delta\|\Delta s_j-\Delta\hat{s}_i\|_2^2+\lambda_t\left|\frac{j}{m}-\frac{i}{n}\right|. \tag{8}$$

其中，$r_{j,i}$ 表示 Agent 第 j 步与专家第 i 个位置之间的初始化匹配代价；$\lambda_\Delta\ge0$ 为状态增量一致性项的权重，用于控制心理变化趋势匹配的重要性；$\lambda_t\ge0$ 为相对时间位置约束项的权重，用于控制序列位置先验的强弱。再据此定义初步传输矩阵 $C^{(0)}$，其元素满足

$$C^{(0)}_{j,i}\propto\exp\left(-\frac{r_{j,i}}{\tau_0}\right). \tag{9}$$

其中，$C^{(0)}_{j,i}$ 表示在回归先验下 Agent 第 j 步与专家第 i 个 item 之间的初步软匹配强度；$\tau_0>0$ 为初始化温度参数，用于控制软匹配分布的平滑程度，τ_0 越小，匹配越尖锐，τ_0 越大，匹配越平滑。最后，将 $C^{(0)}$ 按同一组边缘分布 a 与 b 做归一化。这样，$C^{(0)}$ 就作为后续 UGW 优化中传输矩阵 C 的初始化。

为了显式表示结构对齐代价，定义 Cost function：

$$\ell\big((j,j'),(i,i')\big)=\big(d_A(j,j')-d_E(i,i')\big)^2. \tag{10}$$

它表示：如果把 Agent 侧的第 j,j' 两个位置，对应到专家侧的第 i,i' 两个位置，那么这两对内部结构之间的失真有多大。于是，Unbalanced Gromov-Wasserstein 的对齐损失可以写为：

$$\mathcal{L}_{\mathrm{UGW}}(C)=\sum_{j,j',i,i'}\ell\big((j,j'),(i,i')\big)\,C_{j,i}C_{j',i'}+\varepsilon H(C)+\tau\,\mathrm{KL}(C\mathbf{1}_n\|a)+\tau\,\mathrm{KL}(C^\top\mathbf{1}_m\|b). \tag{11}$$

相应地，最优传输矩阵为：

$$C^\star=\arg\min_{C\in\mathbb{R}_+^{m\times n}}\mathcal{L}_{\mathrm{UGW}}(C). \tag{12}$$

其中 $H(C)$ 为熵正则项，$\varepsilon>0$ 为熵系数，$\tau>0$ 为边缘松弛系数。与普通 GW 相比，UGW 允许两边质量不必完全守恒，因此更适合处理长度不一致、节奏不同或局部无关片段较多的真实行为序列。

策略学习过程

求得传输矩阵 $C^\star$ 后，我们将其转换为 **Agent 当前步骤的 item 级监督信号**。具体地，对 Agent 第 j 步，先定义**归一化匹配权重**

$$q_j(i) = \frac{C^\star_{j,i}}{\sum_{r=1}^{n} C^\star_{j,r} + \delta}, \tag{13}$$

其中 δ 为极小量防止分母为 0。基于 $q_j(i)$，可定义 Agent 第 j 步对应的 item 软目标分布。对任意 item 标识 y，有

$$\hat{q}_j(y) = \sum_{i=1}^{n} q_j(i)\,\mathbf{1}[v_i = y]. \tag{14}$$

也就是说，$\hat{q}_j(v)$ 表示 **在当前 Agent 心理状态下，从结构对齐角度看，专家轨迹中哪些 item 更值得被模仿**。

推理构建阶段

设 Agent 在第 j 步看到的候选 item slate 为实际动作集合为 $\{l_{j,1}, \ldots, l_{j,K}, \mathrm{Skip}\}$）

$$L_j = (l_{j,1}, \ldots, l_{j,K}). \tag{15}$$

其中 K 为候选 item 数。进一步地，将 item 级目标投影到当前动作集合上，得到动作软标签

$$\hat{p}_j(a) = \begin{cases} \hat{q}_j(l_{j,k}), & a = l_{j,k}, \quad k = 1, \ldots, K, \\ 1 - \sum_{k=1}^{K} \hat{q}_j(l_{j,k}), & a = \mathrm{Skip}. \end{cases} \tag{16}$$

这样，$\hat{p}_j$ 构成了定义在 $K+1$ 个动作上的软监督分布。虽然专家侧没有显式动作标签，但通过 UGW 的结构对齐，我们仍然能够为 Agent 当前状态构造出一个合理的动作监督分布。在策略学习阶段，设 ϕ_j 表示第 j 步的策略输入特征，它由当前心理状态以及当前候选动作组成。设策略网络为 $\pi_\theta(\cdot \mid \phi_j)$，其中 θ 为模型参数，则策略网络的训练目标定义为：

$$\mathcal{L}_{policy} = \sum_{j} \mathrm{CE}\big(\hat{p}_j, \pi_\theta(\cdot \mid \phi_j)\big) - \beta H\big(\pi_\theta(\cdot \mid \phi_j)\big). \tag{17}$$

其中 CE 为交叉熵损失，H 为策略熵，β 为熵正则权重。

因此，这里一共包含两层优化目标：

- $\mathcal{L}_{UGW}(C)$：用于求解心理轨迹与行为轨迹之间的结构对齐矩阵 C^*。
- $\mathcal{L}_{policy}$：用于利用 C^* 导出的软标签训练策略网络。

在推理阶段，本方法只使用训练好的策略网络。给定当前心理状态和候选 slate，系统直接输出动作分布并完成决策，因此在线阶段的计算开销极低。