实验方案

1. 研究问题（RQ）

1. `RQ1`：PsyBer-Agent 是否能更真实地复现用户行为分布?
2. `RQ2`：PsyBer-Agent 是否能更准确地进行 A/B 判别（方向+幅度）？
3. `RQ3`：方法是否能跨数据域、跨用户群体泛化?
4. `RQ4`：UGW、OT、Pareto等各模块是否必要?
5. `RQ5`：在大规模仿真下是否具备更优成本-效果比?

Appendix 组实验：

6. `RQ6`：PsyBer-Agent对实现细节和运行条件扰动不敏感？（ Robustness Stress Test）
7. `RQ7`：PsyBer-Agent 案例分析。

2. 数据集设置

1. `MovieLens-1M`：基础主数据集（中等稠密，稳定 benchmark）。
2. `Amazon Review: Musical Instruments`：稀疏+长尾，验证鲁棒性。
3. `Amazon Review: Beauty`：跨品类迁移测试。
4. 划分协议：按用户内时间顺序 `train/val/test=70/10/20`；另保留一组 unseen users 做泛化评测。
5. 报告统计：`#users / #items / #interactions / sparsity / avg session length`。

3. Base Models

1. A/B Test推荐模型：`PopRec`, `BPR-MF`, `LightGCN`, `Multi-VAE`, `GRU4Rec`, `SASRec`, `BERT4Rec`。 （Web Sim平台模型）
2. 用户模拟器 baselines：`Random`， `Rule-based(Pareto-only)`， `LLM-only(Qwen path)`， `BC-only`， `OT-only(no ICVF)`， `Full PsyBer(ICVF+OT+Pareto+Fast)`。
3. 决策 LLM backbone：主模型 `qwen3-vl-flash`；稳健性实验加 `qwen3-vl-plus`（同 prompt、同预算）。

4. Metrics（按任务分组）

1. A/B 判别主指标：`Sign Accuracy`， `Lift MAE`， `Type-I Error`， `Power@δ(1/3/5%)`。
2. 行为拟真指标：`CTR gap`, `Item exposure JS`。
3. 心理状态指标（方法特有）：`PCES trajectory MSE`。
4. 效率指标：`Latency/decision`， `Cost per correct A/B decision`。

为避免不同实验口径不一致，所有实验统一先按任务分组定义主指标，再在各实验中补充必要的辅助诊断指标。

任务组	主指标	典型使用实验
A/B 判别	`Sign Accuracy`, `Lift MAE`, `Type-I Error`, `Power@δ(1/3/5%)`	`E2`, `E3`, `E4`, `E6`
行为拟真	`CTR gap`, `Item exposure JS`	`E1`, `E3`, `E4`, `E6`
心理状态拟真	`PCES trajectory MSE`	`E1`, `E4`, `E6`, `E7`
效率	`Latency/decision`, `Cost per correct A/B decision`	`E2`, `E4`, `E5`, `E6`

统一说明：

- `Sign Accuracy` 作为统一的 A/B 主指标，替代不统一的 `Winner Accuracy` 等命名。
- `Power@δ(1/3/5%)` 在 oracle lift 分别超过 `1%`、`3%`、`5%` 的样本子集上计算。
- `CTR gap` 与 `Item exposure JS` 是行为拟真的 headline metrics，其余行为统计一律作为辅助诊断指标。
- `PCES trajectory MSE` 是方法特有的默认心理状态指标；若需要展示时间错位鲁棒性，可将 `DTW` 放入附录诊断。

5. 实验细则

E1. 行为拟真（Behavior Fidelity）

1. 目标：验证模拟行为分布是否接近真实日志。
2. 输入：test split 中真实用户行为序列。
3. 流程：
    1. 在 train split 上训练各模拟器。
    2. 对 test 用户逐个 rollout，建议使用 `track=50`、`slate=4`。
    3. 生成模拟日志，并与真实 test 日志按用户和时间窗口对齐比较。
4. 指标：
    1. 主指标（行为拟真任务组）：`CTR gap`, `Item exposure JS`。
    2. 方法特有指标（心理状态任务组）：`PCES trajectory MSE`。
    3. 辅助诊断指标：`Skip-rate gap`, `Session length error`, `Repeat rate gap`, `Popularity-bucket JS`, `Transition-matrix distance`。
5. 输出：
    1. 整体 fidelity 指标表。
    2. CTR / exposure-popularity / transition 的分布对比图。
    3. PCES 真实轨迹与模拟轨迹对比图。

E2. 在线 A/B 判别准确性（核心）

1. 目标：在有限流量下，是否能选对推荐系统 winner。
2. 场景：真实模型对，可以参考我们提供的baseline模型，寻找他们的在线A/B test。
3. 流程：
    1. 先运行 `N_oracle`，得到每个 pair 的 oracle winner `winner*` 和 oracle lift `Δ*`。
    2. 在预算 `N ∈ {200, 500, 1000, 2000, 5000}` 下重复实验，并使用多个 seeds。
    3. 每次输出 A/B 结论：`B better`、`A better` 或 `inconclusive`。
4. 指标：
    1. 主指标（A/B 判别任务组）：`Sign Accuracy`，`Lift MAE`，`Type-I Error`，`Power@δ(1/3/5%)`。
    2. 效率指标（效率任务组）：`Cost per correct A/B decision`。
    3. 辅助诊断指标：`Lift RMSE`，`Regret`。
5. 输出：
    1. A/B 判别主结果表。
    2. `Sign Accuracy` vs 流量预算曲线。
    3. `Lift MAE` vs 流量预算曲线。

E3. 跨域与异质性泛化

1. 目标：验证方法在新领域和不同用户群体上的稳定性。
2. 设置：
    1. In-domain：同域训练，同域测试。
    2. Cross-domain zero-shot：在 A数据集上训练，在B数据集上测试。
    3. Few-shot adapt：使用目标域 `5%` 数据微调后测试。
    4. 用户分组：按画像或行为统计聚类，例如高新奇偏好、高认知负荷敏感、高活跃、长尾偏好。
3. 指标：
    1. 主指标（A/B 判别任务组）：`Sign Accuracy`，`Lift MAE`，`Type-I Error`，`Power@δ(1/3/5%)`。
    2. 主指标（行为拟真任务组）：`CTR gap`，`Item exposure JS`。
    3. 泛化与公平性辅助指标：`Worst-group performance`，跨域退化率。
4. 输出：
    1. Table 3：跨域结果表。
    2. Figure 4：分组条形图与 worst-group performance。

E4. 模块消融（Mechanism Study）

1. 目标：证明各模块的必要性。
2. 流程：
    1. 在主数据集和 1 个外部数据集上复现 `E1 + E2` 的关键结果。比如验证Psy-Engine， UWG对齐等模块效用。

    2. 每次移除一个模块，其余设置保持不变。
3. 指标：
    1. 主指标（A/B 判别任务组）：`Sign Accuracy`，`Lift MAE`，`Type-I Error`。
    2. 主指标（行为拟真任务组）：`CTR gap`，`Item exposure JS`。
    3. 主指标（心理状态任务组）：`PCES trajectory MSE`。
    4. 主指标（效率任务组）：`Latency/decision`，必要时补充 `Cost per correct A/B decision`。
4. 输出：
    1. 主消融表。
    2. 模块贡献雷达图或性能降幅图。

E5. 可扩展性与成本效率（Scalability & Cost）

1. 目标：验证大规模可用性和性价比。
2. 规模：`N agents = {100, 500, 1k, 5k, 10k}`，每个点重复 3 次。
3. 工程设置：
    1. 使用 `launch_websim_batch.py` 控制并发。
    2. 记录 wall-clock、吞吐、失败率和超时率。
4. 指标：
    1. 主指标（效率任务组）：`Latency/decision`，`Cost per correct A/B decision`。（时间复杂度，空间复杂度，Token使用量）
    2. 辅助诊断指标：`Throughput`，`Success rate`，`Timeout rate`，`Token/API cost per 10k interactions`。
    3. 固定预算质量分析：在 iso-cost 条件下补充报告 `Sign Accuracy`。
5. 额外分析：
    1. Iso-cost：固定成本下的最佳质量。
    2. Iso-quality：达到目标 `Sign Accuracy` 所需的最小成本。
6. 输出：
    1. 效率表。
    2. Scaling curve。
    3. Cost-quality 曲线。

Appendix：Robustness & Interpretability

E6. 稳健性实验（Robustness Stress Test）

1. 目标：验证方法对实现细节和运行条件扰动不敏感。
2. 扰动维度：

    1. Base LLM：`qwen3-vl-flash` vs `Other LLMs`。
    2. Prompt 扰动：语义改写、指令顺序打乱、加入轻微冗余上下文。
    3. 随机种子扰动：至少 `5–10` 个 seeds。
    4. 轨迹长度扰动：`track=20/50/100`。
3. 设计：
    1. 先做单因素扰动，其余条件固定。
    2. 再做组合压力测试，即模型、prompt、seed、track 同时变化。
4. 指标：
    1. 主指标（A/B 判别任务组）：`Sign Accuracy`，`Lift MAE`，`Type-I Error`，`Power@δ(1/3/5%)`。
    2. 主指标（行为拟真任务组）：`CTR gap`，`Item exposure JS`。
    3. 主指标（心理状态任务组）：`PCES trajectory MSE`。
    4. 主指标（效率任务组）：`Latency/decision`，`Cost per correct A/B decision`。
5. 报告方式：
    1. 每项指标报告 `mean ± 95% CI`。
    2. 额外报告相对退化率 `Drop% = (perturbed - base) / base`。
    3. 单独展示 worst-case performance。

E7. 案例分析（Qualitative Trajectory Analysis）

1. 目标：解释模型全流程工作原理，具体prompt， 优化过程，训练过程，模拟效果。
2. 样本选择：
    1. 展示 `3–5` 条典型轨迹。
    2. 覆盖成功判别、误判、真实 lift 接近 `0` 的边界样本，以及至少 1 条 “状态崩溃-恢复” 轨迹。
3. 每条案例统一展示：
    1. `step`。
    2. 候选动作。
    3. 最终动作（`click/skip`）。
    4. A/B 判别结论。
    5. PCES 状态序列。
    6. 关键心理中间量，例如 `Nov_t`、`Bel_t`、`Offense_t`。
    7. 策略来源（`fast policy` 或 `LLM fallback`）。
4. 可视化：
    1. 一张时间轴图展示动作切换。
    2. 一张 PCES 折线图展示状态演化。
    3. 一段简短的错误归因说明。

5. 结论模板：
    1. 总结何种状态模式下方法更稳定。
    2. 总结何种边界条件下更容易误判。
    3. 将这些观察映射到具体改进方向，例如阈值校准或 prompt 约束。

6. 实验矩阵（E1-E7）

实验	目标	数据集	对比对象	主指标
E1	行为拟真	全部	所有模拟器	CTR/Skip/JS/Transition/PCES
E2	A/B 判别能力（核心）	全部	所有模拟器	Sign Accuracy/Lift MAE/Power/Type-I
E3	跨域与群体泛化	ML-1M→Amazon、群体分簇	Full vs baselines	Lift MAE(分组)/最差组性能
E4	模块消融	主数据集+1外部集	去ICVF/去OT/去Pareto/去Fast	E1+E2核心指标
E5	可扩展性	主数据集	Full vs LLM-only	Throughput/Latency/成本
E6	稳健性	全部	换LLM/换seed/换track	方差、性能下降幅度
E7	案例分析	选代表集	Full	轨迹可解释性+误判分析

具体Metrics定义：

4. Metrics（按任务分组）

1. **A/B 判别主指标**

- `Sign Accuracy`：A/B 效应方向判对的比例。若真实 lift 为正且模型也判为正，或真实为负且模型也判为负，则记为正确。
  含义：衡量方法是否能判断“变好还是变差”。
  越高越好。
- `Lift MAE`：预测 lift 与真实 lift 之间的平均绝对误差，即

$$\frac{1}{N}\sum_{k=1}^{N}|\hat{\Delta}_k - \Delta_k| \tag{1}$$

  其中 $\hat{\Delta}$ 是估计 lift，Δ 是真实 lift。
  含义：衡量效应量估计是否准确。
  越低越好。
- `Type-I Error`：当真实效应为 0，或未达到预设显著阈值时，被错误判成“存在显著差异”的比例。
  含义：衡量方法会不会“乱报有效”。
  越低越好。
- `Power@δ(1/3/5%)`：当真实 lift 的绝对值达到或超过 δ（如 1%、3%、5%）时，方法成功检出该效应的概率。

若你们定义更严格，也可以要求“不仅检出，还要方向判对”。
含义：衡量方法对小效应、中效应、大效应的敏感性。
越高越好。

2. **行为拟真指标**

- `CTR gap`：模拟用户点击率与真实用户点击率之间的差距，通常写为

$$|\widehat{CTR} - CTR_{\text{real}}| \tag{2}$$

含义：衡量整体点击活跃度是否接近真实用户。
越低越好。

- `Item exposure JS`：模拟系统与真实系统在 item 曝光分布上的 Jensen-Shannon divergence。
若 $p(i)$ 是真实曝光分布，$q(i)$ 是模拟曝光分布，则

$$JS(p,q) = \frac{1}{2}KL(p\|m) + \frac{1}{2}KL(q\|m), \quad m = \frac{p+q}{2} \tag{3}$$

含义：衡量模型是否复现了“哪些 item 更常被看到”的整体分布。
越低越好。

3. **心理状态指标（方法特有）**

- `PCES trajectory MSE`：模拟得到的 PCES 心理状态轨迹与参考轨迹之间的均方误差，通常写为

$$\frac{1}{T}\sum_{t=1}^{T} \|\hat{s}_t - s_t\|_2^2 \tag{4}$$

其中 $\hat{s}_t$ 是模型在第 t 步预测的心理状态，s_t 是参考状态。
含义：衡量模型是否能正确复现用户心理状态随交互过程的演化。
越低越好。

4. **效率指标**

- `Latency/decision`：每次行为决策的平均耗时，例如一次点击/跳过决策从输入到输出所需的平均 wall-clock time。
含义：衡量方法是否足够快，能否支撑大规模仿真。
越低越好。

- `Cost per correct A/B decision`：得到一个正确 A/B 结论所需的平均成本，通常可写为

$$\frac{\text{总计算/API成本}}{\text{正确A/B判别数}} \tag{5}$$

含义：衡量方法的实际性价比，而不只是准确率。
越低越好。

如果你愿意，我可以下一步直接把这段整理成论文里的正式英文版。