心理-行为对齐设计

Settings：

设**专家轨迹**为: $E = (i_1, \ldots, i_n)$ 其中， i_t 表示专家在第 t 步点击的物品。

设**Agent心理轨迹**为： $s_j = [C_j, E_j, S_j]^\top \in [0,1]^3$ s_j 是由**心理引擎（Psy-Engine）**定义的三维心理状态，C_j 、 E_j 、 S_j 分别表示：**认知、情绪/社会满足感、自我一致性。**

1.1 心理状态轨迹构建

离线日志仅记录专家的物品点击行为，不含对应的心理状态。为弥补这一缺口，我们先将专家序列 E 在**教师强制（teacher forcing)**模式下，通过同一心理引擎的状态转移，回放构建**专家侧伪心理轨迹**。

从带用户画像的初始状态 $\tilde{s}_0$ 与记忆 $\tilde{M}_0$ 出发，递归计算：

$$\tilde{s}_i = f_\Theta\left(\tilde{s}_{i-1}, \phi\left(i_i\right), \tilde{M}_{i-1}, \rho\right), \quad i = 1, \ldots, n$$

- ρ： 用户画像
- $\phi(i_i)$： 物品 i_i 的心理-行为特征元组（专家在第 i 步所点击的具体物品 i_i 的多维特征表示集合）
- $\tilde{M}_{i-1}$： 第 i 步前的回放记忆状态
- f_Θ： 心理引擎的点击转移分支

由此得到伪心理轨迹：

$$\tilde{A} = (\tilde{s}_1, \ldots, \tilde{s}_n), \tilde{s}_i \in [0,1]^4 \tag{1}$$

为显式刻画局部心理动力学变化，进一步定义**Agent心理状态增量**与**专家伪心理状态增量**的状态增量：

$$\Delta s_j = \begin{cases} s_{j+1} - s_j, & 1 \le j < m, \\ 0, & j = m, \end{cases} \qquad \Delta \tilde{s}_i = \begin{cases} \tilde{s}_{i+1} - \tilde{s}_i, & 1 \le i < n, \\ 0, & i = n. \end{cases}$$

其中：

- Δs_j： 模拟器相邻两步的局部心理变化
- $\Delta \tilde{s}_i$： 专家侧相邻两步的局部心理变化

综上，专家侧提供物品轨迹与**教师强制伪心理演化过程**；Agent侧提供由 PsyBer-Agent 在线生成的真实心理轨迹。这让后续的跨域对齐具备严格定义。

1.2 传输矩阵初始化与 Unbalanced Gromov-Wasserstein (UGW) 对齐

直接均匀初始化传输矩阵 C 效果较差，因为专家物品序列与模拟器心理轨迹是异构数据，且长度可能不同。因此，我们先学习一个**离线回归先验**，将专家前缀映射到与模拟器相同的三维状态空间。具体地，训练回归函数 f_ϕ ：

$$\hat{s}_i = f_\phi\left(\rho, E_{1:i}, \phi\left(i_i\right), \frac{i}{n}\right) \approx \tilde{s}_i, \hat{s}_i \in [0,1]^3$$

- $E_{1:i} = (i_1, \ldots, i_i)$ ： 截至第 i 步的专家前缀
- ϕ ： 回归参数
- $\hat{s}_i$ ： 对齐到Agent状态空间的回归伪状态

通过最小化以下损失离线学习回归参数：

$$\phi^* = \arg\min_\phi \sum_E \sum_{i=1}^n \left\| f_\phi\left(\rho, E_{1:i}, \phi\left(i_i\right), \frac{i}{n}\right) - \tilde{s}_i \right\|_2^2$$

同理定义**回归增量**：

$$\Delta\hat{s}_i = \begin{cases} \hat{s}_{i+1} - \hat{s}_i, & 1 \le i < n, \\ 0, & i = n. \end{cases}$$

给定模拟器状态轨迹 $A = (s_1, \ldots, s_m)$ 与回归后的专家伪状态轨迹 $(\hat{s}_1, \ldots, \hat{s}_n)$ ，定义**Agent第 j 步与专家E第 i 步**之间基于回归的**初始化代价**：

$$r_{j,i} = \left\| s_j - \hat{s}_i \right\|_2^2 + \lambda_\Delta \left\| \Delta s_j - \Delta\hat{s}_i \right\|_2^2 + \lambda_{pos} \left| \frac{j}{m} - \frac{i}{n} \right|$$

- $r_{j,i}$ ： 模拟器第 j 步与专家第 i 步的先验匹配代价
- $\lambda_\Delta \ge 0$ ： 局部心理变化一致性权重
- $\lambda_{pos} \ge 0$ ： 相对位置先验权重

基于该代价，初始化传输矩阵 $C^{(0)} \in \mathbb{R}_+^{m \times n}$ ：

$$C_{j,i}^{(0)} \propto \exp\left(-\frac{r_{j,i}}{\tau_0}\right)$$

- $\tau_0 > 0$ ： 初始化温度，控制软匹配分布的锐度

随后按边缘分布 $a \in \mathbb{R}_+^m$ 、 $b \in \mathbb{R}_+^n$ 归一化 $C^{(0)}$ ； 无特殊说明时，边缘分布设为均匀分布。

初始化传输矩阵C^0：

- **矩阵横向M： 代表Agent侧心理状态轨迹的总步数**
- **矩阵纵向N: 专家侧物品点击行为轨迹的总步数**

初始化后，通过**非平衡格罗莫夫-瓦瑟斯坦（UGW）对齐**优化 C 。

- 专家侧：设 v_i 为 $\phi(i_i)$ 中的融合语义嵌入，定义内部距离：

$$d_E\left(i, i'\right) = \lambda_v \left(1 - \cos\left(v_i, v_{i'}\right)\right) + \lambda_t \left| \frac{i}{n} - \frac{i'}{n} \right|$$

- $\lambda_v \ge 0$ ： 语义差异权重
- $\lambda_t \ge 0$ ： 相对位置差异权重
- 模拟器侧：定义两个心理状态间的内部距离：

$$d_A(j,j') = \lambda_s \|s_j - s_{j'}\|_2 + \lambda_\Delta^A \|\Delta s_j - \Delta s_{j'}\|_2 + \lambda_t^A \left| \frac{j}{m} - \frac{j'}{m} \right|$$

- $\lambda_s \geq 0$： 状态差异权重
- $\lambda_\Delta^A \geq 0$： 增量差异权重
- $\lambda_t^A \geq 0$： 相对位置项权重

两组关系 (j,j') 与 (i,i') 的**结构差异**：

$$\ell\left((j,j'),(i,i')\right) = \left(d_A(j,j') - d_E(i,i')\right)^2$$

对应的 UGW 损失函数：

$$\mathcal{L}_{UGW}(C) = \sum_{j,j',i,i'} \ell\big((j,j'),(i,i')\big) C_{j,i} C_{j',i'} + \varepsilon H(C) + \tau \,\mathrm{KL}\big(C\mathbf{1}_n \,\|\, a\big) + \tau \,\mathrm{KL}\big(C^\top \mathbf{1}_m \,\|\, b\big)$$

- $H(C)$： 熵正则项
- $\varepsilon > 0$： 熵正则权重
- $\tau > 0$： 边缘松弛系数
- $\mathrm{KL}(\cdot|\cdot)$： KL散度

最终传输矩阵：

$$C^* = \arg\min_{C \geq 0} \mathcal{L}_{UGW}(C), \quad C \text{ 由 } C^{(0)} \text{ 初始化}$$

由于优化是非平衡的，学习到的传输方案可自然容忍**轨迹长度不同、浏览速度不同、局部片段不匹配**等情况。

1.3 对齐引导的策略学习软监督

优化后的传输矩阵 C^* 指明每个模拟器步骤最匹配的专家位置。先将其转为**归一化匹配权重**：

$$q_j(i) = \frac{C^*_{j,i}}{\sum_{r=1}^{n} C^*_{j,r} + \delta}$$

- $\delta > 0$： 小常数，保证数值稳定

基于 $q_j(i)$，定义**物品级软目标分布**：

$$\hat{q}_j(y) = \sum_{i=1}^{n} q_j(i) \cdot \mathbf{1}\left[i_i = y\right]$$

- $\hat{q}_j(y)$： 在对齐引导的监督下，分配给物品 y 的概率质量
- 反映与当前模拟器心理状态 s_j 行为最兼容的专家物品

在模拟器第 j 步，设当前候选列表为： $L_j = (l_{j,1}, \ldots, l_{j,K})$

- $l_{j,k}$： 第 k 个候选物品
- K： 列表长度

对应动作空间： $\{l_{j,1}, \ldots, l_{j,K}, \text{skip}\}$

将物品级目标投影到当前动作空间，得到**动作级软标签**：

$$\hat{p}_j(a) = \begin{cases} \hat{q}_j\left(l_{j,k}\right), & a = l_{j,k},\ k = 1, \ldots, K, \\ 1 - \sum_{k=1}^{K} \hat{q}_j\left(l_{j,k}\right), & a = \text{skip}. \end{cases}$$

因此，即便离线专家数据不直接提供当前模拟器候选列表上的动作标签，传输对齐也能基于当前心理状态生成**稠密软监督信号**。

最后，用该软标签定义策略学习的**模仿损失**：

$$L_{\text{imit}} = \sum_j \text{CE}\left(\hat{p}_j, \pi_\theta\left(\cdot | s_j, L_j\right)\right)$$

- $\pi_\theta(\cdot|s_j, L_j)$： 基于当前状态与候选列表、由 θ 参数化的策略网络
- $\text{CE}(\cdot, \cdot)$： 交叉熵损失

该设计让**在线快速策略**能从**心理-行为对齐的软监督**中学习，而非仅依赖稀疏的点击回放。