Psy-Engine Modelling

Psy-Engine 将复杂的心理学概念转化为可计算的数学模型，其核心在于定义好**状态空间 (State Space)**、**输入特征 (Input Features)** 以及**状态转移方程 (State Transition Functions)**。

一、 核心变量与环境定义

我们定义一个离散时间步 t，表示 Agent 每浏览一个页面的过程。

- **智能体内部状态向量$\mathbf{H}_t$ (State Vector):**

  $\mathbf{H}_t = [P_t, C_t, E_t, S_t]^T \in [0, 1]^4$

  分别代表时间 t 时的感知唤醒度、认知储备量、情感满足度、自我协调度。

- **输入特征 (Input):**

  对于时刻 t 推荐的商品/内容 x_t:

  - $\mathbf{v}_t$: 内容的 Embedding 向量。
  - $n_t \in [0, 1]$: 负面偏好度/争议性得分。
  - $c_t \in [0, 1]$: 内容的认知负荷（复杂度）。
  - $pop_t \in [0, 1]$: 社会验证得分（其他 Agent 的点赞/点击率）。

- **智能体自身属性 (Agent Persona):**
  - $M_t = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{t-1}\}$: 浏览历史记忆池。
  - $\mathbf{u}_{ideal}$: 理想自我向量（如：学习、成长类偏好）。
  - $\mathbf{u}_{real}$: 现实自我向量（如：娱乐、即时满足类偏好）。
  - $\mathbf{u}_{base}$: 综合用户画像基线。

二、 四大维度状态转移模型

1. 感知层 (P: Perception Arousal)

目标： 计算受好奇心、负面偏好和历史记忆影响的“感知唤醒度”。

- **新奇感/好奇心 (Nov_t)**：当前内容与记忆库中最相似内容的距离。

  $Nov_t = 1 - \max_{\mathbf{v}_i \in M_t}(\cos(\mathbf{v}_t, \mathbf{v}_i))$

- **内部奖励 (R_t)**：当好奇心被满足时的奖赏。

  $R_t = \sigma(w_r \cdot Nov_t)$

状态转移方程：

$$P_{t+1} = \text{clip}\left(\alpha_1 P_t + \beta_1 Nov_t + \gamma_1 n_t + \delta_1 R_t,\ 0,\ 1\right)$$

(注：α_1 为感知衰减系数，γ_1 控制负面偏好 n_t 对感知的强刺激作用。)

2. 认知层 (C: Cognitive Reserve)

目标： 衡量认知余量（1为精力充沛，0为极度疲劳）。疲劳度与感知层的好奇心相连结。

- **语义饱和度 (Sat_t)**：当前内容与近期短期记忆的同质化程度（取近 k 步）。
  $Sat_t = \frac{1}{k} \sum_{i=t-k}^{t-1} \max(0, \cos(\mathbf{v}_t, \mathbf{v}_i))$
- **启动效应 ($Prim_t$)**：上一条内容的惯性帮助降低认知负荷。
  $Prim_t = \max(0, \cos(\mathbf{v}_t, \mathbf{v}_{t-1}))$

状态转移方程：

$$C_{t+1} = \text{clip}\left(C_t - w_{load} c_t - w_{sat} Sat_t + w_{prim} Prim_t + w_{nov} P_{t+1},\ 0,\ 1\right)$$

(注：负荷 c_t 和语义饱和 Sat_t 扣除认知分数；启动效应 $Prim_t$ 和感知层的唤醒 P_{t+1} 能在一定程度上“回血”补偿疲劳。)

3. 情感/社会层 (E: Emotional Satisfaction)

目标： 衡量归属感、惊喜感及社会验证。

- **归属感 (Bel_t)**：内容与综合画像的相似度。
  $Bel_t = \max(0, \cos(\mathbf{v}_t, \mathbf{u}_{base}))$
- **偶然惊喜感 (Ser_t)**：高新奇感与高归属感的乘积（反差极大却又命中红心）。
  $Ser_t = Nov_t \times Bel_t$
- **社会验证 (SP_t)**：直接引入其他 Agent 的行为统计 pop_t。

状态转移方程：

$$E_{t+1} = \alpha_3 E_t + (1 - \alpha_3) \cdot (\lambda_1 Bel_t + \lambda_2 Ser_t + \lambda_3 SP_t)$$

4. 自我层 (S: Self-Congruence)

目标： 衡量价值观对齐、防范信息茧房及虚度光阴感。

- **茧房/观点激化惩罚 ($Echo_t$)**：如果记忆池 M_t 的方差极小（内容高度集中），且新内容继续加固该观点。
  $Echo_t = \exp(-\text{Var}(M_t)) \cdot \max(0, \cos(\mathbf{v}_t, \mathbf{u}_{base}))$
- **误推冒犯感 ($Offense_t$)**：推荐了极度违背用户画像的内容（禀赋效应受损）。
  $Offense_t = \max(0, \theta - \cos(\mathbf{v}_t, \mathbf{u}_{base}))$ *(其中 θ 为冒犯阈值)*
- **理想/现实博弈负罪感 ($Guilt_t$)**：迎合现实自我，但背离理想自我。

$$Guilt_t = \max(0, \cos(\mathbf{v}_t, \mathbf{u}_{real}) - \cos(\mathbf{v}_t, \mathbf{u}_{ideal}))$$

状态转移方程：

$$S_{t+1} = \text{clip}\left(S_t - \mu_1 Echo_t - \mu_2 Offense_t - \mu_3 Guilt_t + \mu_4 Bel_t,\, 0,\, 1\right)$$

三、 行为预测：基于多目标帕累托最优 (Pareto Optimality)

在给定下一步候选项集 $\mathcal{X}_{cand}$ 时，Agent 需要决定是“点击 (Click)”、“点赞 (Like)”还是“划走 (Skip)”。

因为这四个维度（P, C, E, S）的诉求往往是冲突的（例如：高感知唤醒 P 的“标题党”通常会带来极高的 $Guilt_t$ 从而降低 S），所以 Agent 的行为决策无法单一最大化某一个值，而是遵循**帕累托最优**。

决策机制设计：

1. **状态模拟：** 针对每一个候选动作 $a \in A$，Agent 内部模拟执行该动作后的预期状态增量向量：
   $$\Delta\mathbf{H}(a) = [\Delta P(a), \Delta C(a), \Delta E(a), \Delta S(a)]$$
2. **帕累托支配定义：** 动作 a_1 严格支配动作 a_2 当且仅当：
   $$\forall i \in \{P, C, E, S\}, \Delta H_i(a_1) \geq \Delta H_i(a_2) \quad \text{且} \quad \exists j, \Delta H_j(a_1) > \Delta H_j(a_2)$$
3. **策略选择：** 算法筛选出所有不被任何其他动作支配的候选动作集合，即**帕累托前沿 (Pareto Front)** $\mathcal{P}_{front}$。
4. **最终输出：** Agent 采用 Softmax 机制或 ϵ-贪心策略，在帕累托前沿集合中进行概率采样，输出最终行为。
   $$P(action = a) = \begin{cases} \frac{\exp(\mathbf{w}^T \Delta\mathbf{H}(a))}{\sum_{a' \in \mathcal{P}_{front}} \exp(\mathbf{w}^T \Delta\mathbf{H}(a'))} & a \in \mathcal{P}_{front} \\ 0 & a \notin \mathcal{P}_{front} \end{cases}$$